

Formulation probabiliste

Bayes, entropie et principes d'estimation

Plan du cours

- 1 Langage des probabilités
- 2 Théorie de l'information
- 3 Décision bayésienne
- 4 Maximum de vraisemblance et maximum a posteriori
- 5 Récapitulatif

Pourquoi des probabilités ?

La probabilité est le langage que le machine learning utilise pour traiter l'**incertitude**.

- Les mesures sont bruitées.
- Les facteurs explicatifs ne sont jamais tous observés.
- Les données d'entraînement ne sont qu'un *échantillon* du monde.

Conséquence

Un modèle ne prédit pas une valeur, il prédit une **distribution**.

Une variable aléatoire prend ses valeurs avec des poids positifs qui somment ou s'intègrent à un :



$$\sum_x p(x) = 1 \quad \int p(x) dx = 1, \quad p(x) \geq 0$$

- Variable **discrète** : une fonction de masse, et $p(x)$ est une probabilité.
- Variable **continue** : une **densité**, et la probabilité s'attache à un intervalle,

$$P(a \leq X \leq b) = \int_a^b p(x) dx,$$

jamais à un point isolé.

Discret et continu



À gauche, chaque valeur porte sa propre probabilité et le total fait un. À droite, aucune valeur ne porte de probabilité, c'est l'aire sous la courbe qui en porte une.

Deux variables ont une distribution conjointe $p(x, y)$. Sommer une variable donne la **marginale**, et la conjointe se factorise en une conditionnelle fois une marginale :

$$\underbrace{p(x) = \sum_y p(x, y)}_{\text{r\`egle de la somme}} \quad \underbrace{p(x, y) = p(y | x) p(x)}_{\text{r\`egle du produit}}$$

- En continu, la somme devient une int grale, rien d'autre ne change.
- Deux variables sont **ind pendantes** quand la conjointe est le produit des marginales, $p(x, y) = p(x) p(y)$.

Règle de Bayes

En réarrangeant la règle du produit dans les deux sens, on obtient la règle de Bayes, qui **inverse** une conditionnelle :

$$p(y | x) = \frac{p(x | y) p(y)}{p(x)}$$

- $p(y)$ est l'**a priori** : ce qu'on croit avant d'observer.
- $p(x | y)$ est la **vraisemblance** : la probabilité de l'observation sous chaque hypothèse.
- $p(y | x)$ est l'**a posteriori** : ce qu'on croit après avoir observé.

Le dénominateur ne dépend pas de y

Pour *comparer* deux valeurs de y , on peut donc l'ignorer : $p(y | x) \propto p(x | y) p(y)$.

Dépistage d'une maladie rare

Un test de dépistage détecte 99 % des malades et se trompe sur 5 % des sains. La maladie touche 1 personne sur 1 000. **Votre test est positif : quelle probabilité d'être malade ?**

$$p(M) = 0,001 \quad (\text{a priori})$$

$$p(+ | M) = 0,99 \quad (\text{vraisemblance})$$

$$p(+ | \bar{M}) = 0,05$$

$$p(+) = \underbrace{0,99 \times 0,001}_{0,00099} + \underbrace{0,05 \times 0,999}_{0,04995} = 0,0509$$

$$p(M | +) = \frac{0,00099}{0,0509} \approx 1,9 \%$$

L'intuition se trompe

Un test à 99 % ne donne pas 99 % de certitude. L'a priori écrase la vraisemblance quand la classe est rare.

Plan du cours


- 1 Langage des probabilités
- 2 Théorie de l'information**
- 3 Décision bayésienne
- 4 Maximum de vraisemblance et maximum a posteriori
- 5 Récapitulatif

L'entropie d'une distribution mesure son **incertitude** : le nombre moyen de bits nécessaires pour décrire une issue.

$$H(X) = - \sum_x p(x) \log p(x)$$

- Elle ne dépend pas des **valeurs** prises, seulement de leurs probabilités.
- Maximale quand toutes les issues sont équiprobables.
- Nulle quand une issue est certaine : il n'y a plus rien à apprendre.

Entropie binaire



Pour une variable à deux issues, l'entropie est maximale en $p = 0,5$, là où l'issue est la plus difficile à prévoir, et nulle quand une issue est certaine.

Entropie croisée et divergence KL

L'**entropie croisée** mesure le coût d'utiliser un modèle q quand la vérité est p .
La **divergence de Kullback-Leibler** mesure à quelle distance q se trouve de p :

$$H(p, q) = - \sum_x p(x) \log q(x) \quad D_{\text{KL}}(p \parallel q) = \sum_x p(x) \log \frac{p(x)}{q(x)} \geq 0$$

- $H(p, q) = H(p) + D_{\text{KL}}(p \parallel q)$: l'entropie du vrai, plus le prix de l'erreur de modèle.
- $D_{\text{KL}}(p \parallel q) = 0$ si et seulement si $q = p$. Ce n'est pas une distance : elle n'est pas symétrique.

L'entropie croisée est une vraisemblance

À retenir

Minimiser l'entropie croisée entre les vraies étiquettes et les prédictions d'un modèle revient exactement à **maximiser la vraisemblance** de ces étiquettes.

- C'est pourquoi tous les réseaux de classification minimisent l'entropie croisée.
- C'est aussi le premier exemple d'un pattern qu'on retrouve(ra) sans arrêt : *une hypothèse probabiliste produit une fonction de coût.*

Hypothèse sur le bruit $\longrightarrow$ fonction de coût $\longrightarrow$ algorithme

Plan du cours


- 1 Langage des probabilités
- 2 Théorie de l'information
- 3 Décision bayésienne**
- 4 Maximum de vraisemblance et maximum a posteriori
- 5 Récapitulatif

Pour classer une entrée x , la règle bayésienne utilise l'a posteriori sur les classes. Sous la perte 0-1, la décision qui minimise la perte espérée est simplement la **classe la plus probable** :

$$\hat{y} = \arg \max_y p(y | x) = \arg \max_y p(x | y) p(y)$$

- La seconde forme utilise la proportionnalité de la page « règle de Bayes » : le dénominateur $p(x)$ est le même pour toutes les classes.
- Elle est plus commode : $p(x | y)$ et $p(y)$ s'estiment classe par classe.

Frontière de décision



Chaque classe apporte sa densité mise à l'échelle par son a priori, et la frontière de décision tombe là où les deux sont égales. De chaque côté, la classe au plus grand a posteriori l'emporte.

Résultat

Aucun classifieur ne fait mieux que celui-là. On l'appelle le **classifieur de Bayes**, et son taux d'erreur (*l'erreur de Bayes*) est le plancher incompressible du problème.

- Il suppose connues les vraies densités $p(x | y)$ et les vrais a priori $p(y)$. On ne les connaît jamais.
- **Certaines méthodes** (régression logistique, arbres, SVM, réseaux de neurones) est une tentative d'approcher ces a posteriori à partir des données.

D'où la suite

Puisqu'on ne connaît pas les distributions, il faut les **estimer**. C'est l'objet de la section suivante.

Plan du cours

- 1 Langage des probabilités
- 2 Théorie de l'information
- 3 Décision bayésienne
- 4 Maximum de vraisemblance et maximum a posteriori**
- 5 Récapitulatif

On connaît rarement la vraie distribution. On suppose donc une **famille** de distributions indexée par des paramètres w , et on choisit le w que les données désignent.

Deux principes :

- Le **maximum de vraisemblance** (MV) : quel w rend les données observées les plus probables ?
- Le **maximum a posteriori** (MAP) : même question, mais en tenant compte de ce qu'on croit *a priori* sur w .

Le maximum de vraisemblance choisit le w qui rend les données observées les plus probables :

$$w_{\text{MV}} = \arg \max_w \sum_{i=1}^m \log p(x^{(i)} | w)$$

- Les exemples étant **indépendants**, leur probabilité conjointe est un **produit** :
 $p(D | w) = \prod_{i=1}^m p(x^{(i)} | w)$.
- Le logarithme le transforme en somme.

Pourquoi le logarithme ?

Trois raisons, toutes pratiques :

- Le log est **strictement croissant** : il ne déplace pas l'argmax.
- Un produit de m densités devient une **somme**, donc dérivable terme à terme.
- Un produit de 10^6 nombres < 1 vaut numériquement zéro. Une somme de logarithmes, non.

$$\arg \max_w \prod_{i=1}^m p_i(w) = \arg \max_w \sum_{i=1}^m \log p_i(w)$$

Réflexe

Devant une vraisemblance, on écrit toujours la **log-vraisemblance**.

En apprentissage **supervisé**, on ne modélise pas $p(x)$: le modèle paramètre la conditionnelle $p(y \mid x; w)$. Le même principe s'applique donc à la vraisemblance conditionnelle des cibles :

$$\ell(w) = \sum_{i=1}^m \log p(y^{(i)} \mid x^{(i)}; w)$$

Deux faces d'un même objectif

Maximiser ℓ revient à minimiser le coût $J(w) = -\ell(w)$. La vue *par la vraisemblance* et la vue *par minimisation du coût* sont le même problème écrit dans deux sens.


Maximum a posteriori

Le maximum de vraisemblance ne connaît que les données. Le maximum a posteriori maximise l'a posteriori, qui multiplie la vraisemblance par un **a priori** sur w :

$$w_{\text{MAP}} = \arg \max_w \underbrace{p(D | w)}_{\text{vraisemblance}} \underbrace{p(w)}_{\text{a priori}}$$

- Le MAP est le MV **augmenté d'un a priori**. Avec $p(w)$ uniforme, les deux coïncident.
- Avec beaucoup de données, la vraisemblance domine : l'a priori s'efface et les deux estimateurs convergent l'un vers l'autre.

L'a priori tire les paramètres vers zéro



A priori gaussien : pénalité L_2 .

A priori de Laplace : pénalité L_1 .

Le MAP est la régularisation

Équivalence à retenir

Ajouter un a priori sur les paramètres, c'est ajouter une **pénalité** à la fonction de coût. Ce ne sont pas deux idées voisines : c'est la même, écrite en probabilités d'un côté et en optimisation de l'autre.

Vue probabiliste	Vue optimisation
Maximiser $\log p(D w)$	Minimiser le coût $J(w)$
A priori gaussien $\mathcal{N}(0, \tau^2 I)$	Pénalité $\lambda \ w\ _2^2$ (ridge)
A priori de Laplace	Pénalité $\lambda \ w\ _1$ (lasso)
A priori plus serré	λ plus grand

Plan du cours

- 1 Langage des probabilités
- 2 Théorie de l'information
- 3 Décision bayésienne
- 4 Maximum de vraisemblance et maximum a posteriori
- 5 **Récapitulatif**

	Formule
Somme et produit	$p(x) = \sum_y p(x, y), \quad p(x, y) = p(y x) p(x)$
Règle de Bayes	$p(y x) = \frac{p(x y) p(y)}{p(x)}$
Entropie	$H(X) = - \sum_x p(x) \log p(x)$
Entropie croisée	$H(p, q) = - \sum_x p(x) \log q(x)$
Classifieur de Bayes	$\hat{y} = \arg \max_y p(x y) p(y)$
Maximum de vraisemblance	$w_{\text{MV}} = \arg \max_w \sum_i \log p(x^{(i)} w)$
Maximum a posteriori	$w_{\text{MAP}} = \arg \max_w p(D w) p(w)$

- Deux règles suffisent : la **somme** et le **produit**. Tout le reste en découle.
- La règle de Bayes **inverse** une conditionnelle : l'a posteriori est la vraisemblance fois l'a priori. Quand la classe est rare, l'a priori écrase la vraisemblance.
- L'entropie croisée est la vraisemblance écrite comme un **coût**.
- Sous la vraie loi, le **classifieur de Bayes** est optimal.
- Le **maximum de vraisemblance** choisit le w qui rend les données les plus probables ; le **maximum a posteriori** y ajoute un a priori, c'est-à-dire une pénalité.

Ces deux principes ne restent pas abstraits. Appliqués à une seule hypothèse linéaire, ils produisent :

- le **maximum de vraisemblance** sous bruit gaussien donne les **moindres carrés** ;
- le **maximum a posteriori** sous a priori gaussien donne la **régression ridge**.

Pattern

Une hypothèse probabiliste $\longrightarrow$ une fonction de coût $\longrightarrow$ un algorithme.