

Régression linéaire

Des moindres carrés à la régularisation

Plan du Cours

- 1 Le modèle linéaire et les moindres carrés
- 2 D'où viennent les moindres carrés
- 3 Le ridge : rétrécir sans annuler
- 4 Le lasso : annuler pour sélectionner
- 5 Fonctions de base et prédictions multiples
- 6 Récapitulatif

Deux principes d'estimation

Rappel :

$$w_{\text{MV}} = \arg \max_w p(D \mid w)$$

$$w_{\text{MAP}} = \arg \max_w p(D \mid w) p(w)$$

- Le **maximum de vraisemblance** choisit le w qui rend les données observées les plus probables.
- Le **maximum a posteriori** y ajoute un a priori sur w , et un a priori, écrit du côté de l'optimisation, est une pénalité : gaussien pour L_2 , Laplace pour L_1 .
- En supervisé, la vraisemblance porte sur les cibles : $\ell(w) = \sum_i \log p(y^{(i)} \mid x^{(i)}; w)$, et maximiser ℓ revient à minimiser le coût $J(w) = -\ell(w)$.

- 1 Le modèle linéaire et les moindres carrés
- 2 D'où viennent les moindres carrés
- 3 Le ridge : rétrécir sans annuler
- 4 Le lasso : annuler pour sélectionner
- 5 Fonctions de base et prédictions multiples
- 6 Récapitulatif


Hypothèse la plus simple

La régression linéaire prédit une **cible continue** à partir d'un score linéaire.

L'hypothèse est linéaire en l'entrée augmentée $x \in \mathbb{R}^{n+1}$:

$$h_w(x) = w^T x = w_0 + w_1 x_1 + \dots + w_n x_n$$

- w_0 : le **biais** (l'ordonnée à l'origine).
- $w_1, \dots, w_n$: les **poids**, un par caractéristique.



Convention $x_0 = 1$



Écrire le biais séparément alourdit toutes les formules. On ajoute donc une caractéristique **fictive** qui vaut toujours 1 :

$$x = \begin{bmatrix} 1 \\ x_1 \\ \vdots \\ x_n \end{bmatrix} \quad w = \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_n \end{bmatrix}$$

$$w^T x = w_0 \cdot 1 + \sum_{j=1}^n w_j x_j$$

Les deux vecteurs ont taille $n + 1$.

Droite, plan, hyperplan



Avec une caractéristique le modèle trace une droite à travers les données, avec deux un plan, et au-delà un hyperplan que l'on ne peut plus dessiner.

Matrice de conception X

Le produit scalaire vaut pour *un* exemple. En empilant les m exemples en lignes, tout le jeu de données se traite d'un coup.

$$X = \begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \dots \\ 1 & x_1^{(2)} & x_2^{(2)} & \dots \\ \vdots & \vdots & \vdots & \ddots \\ 1 & x_1^{(m)} & x_2^{(m)} & \dots \end{bmatrix} \in \mathbb{R}^{m \times (n+1)}$$

- m lignes : les exemples.
- $n + 1$ colonnes : les caractéristiques *plus* la colonne de 1 du biais.
- La i -ème ligne est $(x^{(i)})^T$.

$$\hat{y} = Xw \in \mathbb{R}^m$$

Problème à résoudre



Étant donné l'ensemble d'entraînement $\{(x^{(i)}, y^{(i)})\}_{i=1}^m$, on voudrait idéalement $h_w(x^{(i)}) = y^{(i)}$ en chaque point.

Les cibles réelles sont **bruitées** (erreurs de mesure, facteurs non modélisés) : aucune droite ne passe par toutes. Le but devient de commettre la plus petite erreur totale.

$$w^* = \arg \min_w \sum_{i=1}^m \left(w^T x^{(i)} - y^{(i)} \right)^2$$

Les **moindres carrés** prennent le résidu au carré comme erreur et le somment sur l'ensemble d'entraînement. Sous forme matricielle : $\|Xw - y\|^2$.

Cibles idéales et cibles bruitées




Sans bruit, le modèle pourrait passer par chaque point. Les cibles réelles se dispersent autour de la tendance, chaque point laisse donc un résidu, et l'ajustement minimise leur somme des carrés (segments gris).

Une surface convexe

La somme des carrés est une **quadratique** en w . Elle dessine dans l'espace des paramètres un **bol convexe**.

Propriété clé

Pas de minimum local : tout minimum est global. C'est ce qui rendra la forme close possible.



Pourquoi le carré ?

- Pourquoi le carré plutôt que, disons, la **valeur absolue** ?
- Les réponses habituelles sont faibles : « ça rend les erreurs positives », « c'est dérivable », « ça pénalise davantage les grandes erreurs ». La valeur absolue fait les deux premières.
- Ce n'est pas un choix de commodité : le carré est **prouvé optimal quand le bruit est gaussien**.
- Il suffit pour le voir de poser un **modèle génératif** sur les données, puis d'y appliquer le maximum de vraisemblance.

Plan du cours

- 1 Le modèle linéaire et les moindres carrés
- 2 D'où viennent les moindres carrés**
- 3 Le ridge : rétrécir sans annuler
- 4 Le lasso : annuler pour sélectionner
- 5 Fonctions de base et prédictions multiples
- 6 Récapitulatif

Hypothèse de bruit gaussien

On part du principe que chaque cible est la prédiction linéaire **plus un bruit gaussien indépendant**.

$$y^{(i)} = w^T x^{(i)} + \varepsilon^{(i)}, \quad \varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$$

- Autrement dit $p(y^{(i)} | x^{(i)}; w) = \mathcal{N}(w^T x^{(i)}, \sigma^2)$.
- Le modèle ne prédit plus une valeur mais une **distribution**, centrée sur la droite.
- Le bruit est **le même** pour tous les points (σ^2 constant) et **indépendant** d'un point à l'autre.

Le maximum de vraisemblance donne les moindres carrés

Le maximum de vraisemblance choisit les paramètres sous lesquels les cibles observées sont les plus probables. Sous ce bruit gaussien, il tombe **exactement** sur les moindres carrés :

$$w_{\text{MV}} = \arg \max_w p(y \mid X; w) = \arg \min_w \sum_{i=1}^m \left(y^{(i)} - w^T x^{(i)} \right)^2$$

Preuve (1/2) : de la vraisemblance à la log-vraisemblance

Mise en place

Les exemples sont i.i.d., la vraisemblance de tout l'ensemble d'entraînement se factorise donc en un produit de densités gaussiennes.

$$p(y \mid X; w) = \prod_{i=1}^m p(y^{(i)} \mid x^{(i)}; w) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y^{(i)} - w^T x^{(i)})^2}{2\sigma^2}\right)$$

Le logarithme est croissant : il préserve l'argmax et transforme le produit en somme.

Preuve (2/2) : la somme des carrés apparaît

$$\ell(w) = \sum_{i=1}^m \log \mathcal{N}(y^{(i)} \mid w^T x^{(i)}, \sigma^2) = \underbrace{-\frac{m}{2} \log(2\pi\sigma^2)}_{\text{indépendant de } w} - \frac{1}{2\sigma^2} \sum_{i=1}^m (y^{(i)} - w^T x^{(i)})^2$$

Conclusion

Le premier terme ne dépend pas de w . Le facteur $\frac{1}{2\sigma^2}$ est une constante *positive*. Aucun des deux ne déplace l'argmax. Maximiser ℓ revient donc à **minimiser la somme des erreurs au carré**. ■

- Remarquez que σ^2 disparaît : la valeur du bruit n'influence pas w_{MV} .

Le minimiseur a une **forme close**, avec X la matrice de conception :

$$w_{MV} = (X^T X)^{-1} X^T y$$

- C'est possible parce que la somme des carrés est une quadratique **convexe** : son minimum global est le point de gradient nul.

Gradient nul

Sous forme matricielle, la somme des carrés est $\|Xw - y\|^2$, une fonction convexe de w . Son minimum global est donc le point où le gradient s'annule.

$$\nabla_w \|Xw - y\|^2 = 2X^T(Xw - y) = 0 \iff X^T X w = X^T y$$

Pourvu que $X^T X$ soit inversible, isoler w donne $w_{MV} = (X^T X)^{-1} X^T y$. ■

Plan du cours

- 1 Le modèle linéaire et les moindres carrés
- 2 D'où viennent les moindres carrés
- 3 Le ridge : rétrécir sans annuler
- 4 Le lasso : annuler pour sélectionner
- 5 Fonctions de base et prédictions multiples
- 6 Récapitulatif

Le maximum a posteriori donne la régression ridge

Le maximum de vraisemblance peut **surapprendre**.

Le maximum a posteriori multiplie la vraisemblance par un a priori gaussien centré sur les paramètres :

$$w_{\text{MAP}} = \arg \max_w p(y \mid X, w) p(w), \quad w \sim \mathcal{N}(0, \tau^2 I)$$

Ce que l'a priori dit

« Avant de voir les données, je crois les coefficients **petits**. » τ mesure la largeur de cette croyance : τ petit, croyance serrée ; τ grand, croyance vague.

L'a priori gaussien devient la pénalité L_2

$$w_{\text{MAP}} = \arg \min_w \sum_{i=1}^m \left(y^{(i)} - w^T x^{(i)} \right)^2 + \lambda \|w\|_2^2, \quad \lambda = \frac{\sigma^2}{\tau^2}$$

- C'est la **régression ridge**. La pénalité est souvent appelée *weight decay*.
- λ n'est pas un réglage arbitraire : c'est le **rapport** entre le bruit des données et la largeur de l'a priori.
- Plus les données sont bruitées (σ grand) ou plus l'a priori est serré (τ petit), plus la pénalité est lourde.

Preuve (1/2) : a posteriori et log

Mise en place

Par la règle de Bayes, $p(w | y, X) = \frac{p(y | X, w) p(w)}{p(y | X)}$, et le dénominateur ne dépend pas de w . Maximiser l'a posteriori revient donc à maximiser vraisemblance $\times$ a priori.

La covariance de l'a priori est inconnue, on la suppose **isotropique**, $\tau^2 I$:

$$p(w) = \frac{1}{(2\pi\tau^2)^{(n+1)/2}} \exp\left(-\frac{\|w\|^2}{2\tau^2}\right)$$

En prenant le logarithme et en réutilisant $\ell(w)$ de la preuve précédente :

$$\log p(y | X, w) + \log p(w) = \text{const} - \frac{1}{2\sigma^2} \sum_{i=1}^m \left(y^{(i)} - w^T x^{(i)}\right)^2 - \frac{1}{2\tau^2} \|w\|^2$$

Preuve (2/2) : le rapport σ^2/τ^2

La constante rassemble tous les termes indépendants de w . Multiplier par $-2\sigma^2$ (une constante **négative**, qui change l'argmax en argmin) laisse :

$$w_{\text{MAP}} = \arg \min_w \sum_{i=1}^m \left(y^{(i)} - w^T x^{(i)} \right)^2 + \frac{\sigma^2}{\tau^2} \|w\|^2$$

Conclusion

En posant $\lambda = \sigma^2/\tau^2$, on retrouve exactement l'objectif ridge. La pénalité L_2 est l'a priori gaussien, écrit du côté de l'optimisation. ■

Ici σ^2 ne disparaît plus : c'est lui qui fixe le poids relatif des deux termes.

Le minimiseur pénalisé garde une **forme close** :

$$w_{\text{MAP}} = (X^T X + \lambda I)^{-1} X^T y$$

- $\lambda \rightarrow 0$ retrouve le maximum de vraisemblance.
- Un λ croissant **rétrécit** w vers zéro et combat le surapprentissage.
- Une seule ligne de différence avec l'équation normale : le $+\lambda I$.

Preuve : la forme close du ridge

Encore un gradient nul

L'objectif matriciel est $\|Xw - y\|^2 + \lambda\|w\|^2$, toujours une quadratique convexe.

$$\nabla_w (\|Xw - y\|^2 + \lambda\|w\|^2) = 2X^T(Xw - y) + 2\lambda w = 0 \iff (X^T X + \lambda I) w = X^T y$$

Pour $\lambda > 0$, la matrice $X^T X + \lambda I$ est définie positive (donc inversible) **sans condition sur X** cette fois : pour tout $v \neq 0$,


$$v^T (X^T X + \lambda I) v = \|Xv\|^2 + \lambda\|v\|^2 > 0$$

Isoler w donne $w_{\text{MAP}} = (X^T X + \lambda I)^{-1} X^T y$. ■

Géométrie du ridge

Minimiser sous pénalité L_2 équivaut à minimiser sous la **contrainte** $\|w\|_2 \leq t$.

- La solution est la **tangence** entre les contours de l'erreur et le disque de contrainte.
- Le disque est **lisse** : la tangence tombe presque toujours en un point où *aucune* coordonnée n'est nulle.
- D'où le comportement du ridge : il rétrécit les poids, il ne les **annule jamais**.



Toujours standardiser d'abord

Les pénalités dépendent de l'unité : passer une surface de cm^2 en m^2 exempté son poids de la pénalité.

Plan du cours

- 1 Le modèle linéaire et les moindres carrés
- 2 D'où viennent les moindres carrés
- 3 Le ridge : rétrécir sans annuler
- 4 Le lasso : annuler pour sélectionner**
- 5 Fonctions de base et prédictions multiples
- 6 Récapitulatif

L'a priori gaussien donnait la pénalité L_2 . Un a priori de **Laplace** donne plutôt la pénalité L_1 :

$$w_{\text{lasso}} = \arg \min_w \sum_{i=1}^m \left(y^{(i)} - w^T x^{(i)} \right)^2 + \lambda \|w\|_1$$

- Un carré remplacé par une valeur absolue. Le changement paraît minime.
- Ses conséquences ne le sont pas.


Pourquoi le lasso sélectionne

La région de contrainte $\|w\|_1 \leq t$ est un **losange** dont les coins sont sur les axes.

Les contours elliptiques de l'erreur touchent un **coin** d'abord, là où une coordonnée est exactement nulle.

Différence

Le ridge **stabilise**, le lasso **sélectionne**. La boule L_2 arrondie n'a pas de coins à accrocher.



Plan du cours

- 1 Le modèle linéaire et les moindres carrés
- 2 D'où viennent les moindres carrés
- 3 Le ridge : rétrécir sans annuler
- 4 Le lasso : annuler pour sélectionner
- 5 Fonctions de base et prédictions multiples**
- 6 Récapitulatif

La droite est souvent trop rigide

Trajectoire d'une balle, croissance bactérienne, saturation d'un signal : une droite ne peut pas suivre une tendance courbe.

C'est le **sous-apprentissage** : erreur élevée en entraînement *et* en test.


On n'abandonne pas le linéaire

On **projette** x **dans un espace plus grand**, où la relation redevient linéaire. Toute la machinerie précédente s'y applique telle quelle.

$$h_w(x) = w^T \phi(x) = \sum_{j=0}^{M-1} w_j \phi_j(x), \quad \phi_0(x) = 1$$

- Les ϕ_j sont des **fonctions de base**, fixées *avant* l'entraînement.
- Avec $\phi(x) = (1, x, x^2, \dots, x^d)$ on retrouve la **régression polynomiale**.
- Avec $\phi(x) = x$ on retrouve exactement tout ce qui précède.

Danger des degrés élevés



Attention

Plus la base est grande, plus le modèle est flexible, et plus il risque de mémoriser le bruit.

On empile les $\phi(x^{(i)})^T$ comme lignes de la matrice de conception $\Phi \in \mathbb{R}^{m \times M}$, et **rien ne change** dans l'ajustement :

$$w_{\text{MV}} = (\Phi^T \Phi)^{-1} \Phi^T y, \quad w_{\text{MAP}} = (\Phi^T \Phi + \lambda I)^{-1} \Phi^T y$$

- Les deux preuves de tout à l'heure se relisent en remplaçant X par Φ .
- Avec M grand, $\Phi^T \Phi$ devient facilement mal conditionnée. Le $+\lambda I$ devient alors essentiel.

Ce qui s'apprend et ce qui se choisit

Appris (par les données)	Choisi (avant l'entraînement)
les paramètres w	la famille de base ϕ sa taille M la pénalité λ

Sélection de modèle

Choisir M et λ est un problème d'**hyperparamètres**.

M trop petit : sous-apprentissage. M trop grand avec λ trop petit : surapprentissage.

Prédictions multiples

Rien ne restreint la cible à un seul nombre. Pour prédire K valeurs à la fois (le prix d'une maison, son coût de chauffage et ses taxes à partir des mêmes caractéristiques), chaque sortie reçoit sa **colonne** de paramètres :

$$h_W(x) = W^T \phi(x) \in \mathbb{R}^K, \quad W \in \mathbb{R}^{M \times K}$$

En empilant les cibles comme lignes de $Y \in \mathbb{R}^{m \times K}$, les mêmes dérivations résolvent les K régressions d'un coup :

$$W_{\text{MV}} = (\Phi^T \Phi)^{-1} \Phi^T Y, \quad W_{\text{MAP}} = (\Phi^T \Phi + \lambda I)^{-1} \Phi^T Y$$

$(\Phi^T \Phi)^{-1}$ ne dépend pas des cibles

Une seule inversion pour K sorties

Le facteur coûteux — $(\Phi^T \Phi)^{-1}$, ou $(\Phi^T \Phi + \lambda I)^{-1}$ pour le ridge — se calcule donc **une seule fois** et se partage entre les K sorties.

- K régressions indépendantes coûtent donc à peine plus qu'une seule.
- Les K sorties partagent la base ϕ mais pas les poids : aucune information ne circule entre elles.
- C'est précisément ce que les réseaux de neurones changeront, en partageant aussi les représentations intermédiaires.

- 1 Le modèle linéaire et les moindres carrés
- 2 D'où viennent les moindres carrés
- 3 Le ridge : rétrécir sans annuler
- 4 Le lasso : annuler pour sélectionner
- 5 Fonctions de base et prédictions multiples
- 6 Récapitulatif**

	Formule
Modèle	$h_w(x) = w^T \phi(x)$
Maximum de vraisemblance (moindres carrés)	$w_{\text{MV}} = (\Phi^T \Phi)^{-1} \Phi^T y$
Maximum a posteriori (ridge)	$w_{\text{MAP}} = (\Phi^T \Phi + \lambda I)^{-1} \Phi^T y$
Lasso (L_1)	pas de forme close, solveur convexe
Paramètres, appris	w , ou W pour K sorties
Hyperparamètres, choisis par validation	la base ϕ , sa taille M , la pénalité λ