

Introduction au Machine Learning

Table des matières

- 1 Introduction au Machine Learning
- 2 Les Types d'Apprentissage
- 3 Classification
- 4 Régression
- 5 Evaluer un modèle
- 6 Défis de l'apprentissage automatique
- 7 Conclusion

Qu'est-ce que le Machine Learning ?

Définition (Arthur Samuel, 1959)

« [L'apprentissage automatique est la] discipline donnant aux ordinateurs la capacité d'apprendre sans qu'ils soient explicitement programmés. »

Définition (Tom Mitchell, 1997)

« Étant donné une tâche **T** et une mesure de performance **P**, on dit qu'un programme informatique apprend à partir d'une expérience **E** si les résultats obtenus sur **T**, mesurés par **P**, s'améliorent avec l'expérience **E**. »

Exemple : Le filtre anti-spam

- **Tâche (T)** : Identifier les e-mails frauduleux (spam) parmi les nouveaux e-mails.
- **Expérience (E)** : Les données d'entraînement (exemples de spam et de "ham" signalés par les utilisateurs).
- **Mesure (P)** : Le pourcentage d'e-mails correctement classés (la justesse ou "accuracy").
- **Modèle** : La partie du système qui apprend et fait les prédictions (ex : un réseau de neurones, une forêt aléatoire).

Pourquoi utiliser le Machine Learning ?

Approche Traditionnelle (Ex : Filtre Spam)

- 1 Examiner les spams (repérer "gratuit", "carte bancaire"...).
- 2 Écrire des règles explicites (if "gratuit" in subject, then spam).
- 3 Tester et ajuster les règles manuellement.
- 4 Répéter à l'infini.



Problème : Devient une liste de règles complexes, difficile à maintenir.

Approche Machine Learning

- 1 Fournir des exemples de spam et de "ham" à un algorithme.
- 2 Le modèle apprend *automatiquement* les mots et associations qui prédisent le mieux le spam.

Avantage : Plus court, plus facile à maintenir, souvent plus performant.

Approche Traditionnelle vs Machine Learning



L'apprentissage automatique est excellent pour :


- Les problèmes nécessitant beaucoup d'ajustements fins ou de **longues listes de règles** (ex : détection de spam).
- Les **problèmes complexes** pour lesquels aucune solution traditionnelle n'existe (ex : reconnaissance vocale, analyse d'image).
- Les **environnements fluctuants** (le système peut se ré-entraîner et s'adapter à de nouvelles données).
- L'exploration de **gros volumes de données** pour y découvrir des structures cachées (Data Mining).



Classification d'images

- **Exemple** : Tri de produits sur une chaîne de production
- **Techniques** : CNN, Transformateurs
- Identification automatique d'objets dans des images


Exemples d'Applications : Segmentation sémantique



Segmentation sémantique

- **Exemple** : Détection de tumeurs sur scanners
- **Techniques** : CNN, Transformateurs
- Identification précise de régions dans des images médicales

Exemples d'Applications : Traitement du Langage (TALN)



Traitement du Langage (TALN)

- **Exemples** : Classification d'articles, chatbots, résumé auto
- **Techniques** : RNR, Transformateurs
- Compréhension et génération de texte automatique


Exemples d'Applications : Régression (Prévision)



Régression (Prévision)

- **Exemple** : Prévoir les résultats financiers
- **Techniques** : Régression linéaire, Forêts aléatoires, RNR
- Prédiction de valeurs numériques continues


Exemples d'Applications : Détection d'anomalies



Détection d'anomalies

- **Exemple** : Fraude de carte bancaire
- **Techniques** : Forêts d'isolation, Autoencodeurs
- Identification de comportements inhabituels

Exemples d'Applications : Partitionnement (Clustering)



Partitionnement (Clustering)

- **Exemple** : Segmentation de clientèle
- **Techniques** : k-moyennes, DBSCAN
- Découverte de groupes naturels dans les données

Exemples d'Applications : Apprentissage par renforcement



Apprentissage par renforcement

- **Exemple** : IA pour les jeux comme AlphaGo
- Apprentissage par interaction avec l'environnement
- Optimisation de stratégies par essai-erreur

Table des matières

- 1 Introduction au Machine Learning
- 2 Les Types d'Apprentissage**
- 3 Classification
- 4 Régression
- 5 Evaluer un modèle
- 6 Défis de l'apprentissage automatique
- 7 Conclusion

La principale distinction se fait selon **la nature et l'importance de la supervision humaine** durant l'entraînement.

- ➊ **Apprentissage Supervisé**
- ➋ **Apprentissage Non Supervisé**

(Il en existe d'autres, comme l'apprentissage semi-supervisé ou par renforcement.)

Le système apprend avec un professeur.

- Les données d'entraînement fournies à l'algorithme **comportent les solutions désirées**.
- Ces solutions sont appelées des **étiquettes** (en anglais, *labels*).
- L'objectif est d'apprendre à prédire l'étiquette pour de nouvelles données.

1. Classification

- L'étiquette est une **catégorie** ou une classe.
- **Exemple** : Le filtre anti-spam. L'étiquette est "Spam" ou "Ham" (Normal).
- **Exemple** : Reconnaissance de chiffres. L'étiquette est 0, 1, 2, 3, 4, 5, 6, 7, 8, ou 9.

2. Régression

- L'étiquette est une **valeur numérique** continue.
- **Exemple** : Prédire le prix d'une voiture.
- Les données d'entrée (kilométrage, âge, marque) sont les **prédicteurs** ou **caractéristiques** (features).
- La valeur à prédire (prix) est la **cible** (target).

Le système apprend sans professeur.

- Les données d'apprentissage **ne sont pas étiquetées**.
- Le système essaie de **découvrir des structures ou des motifs cachés** dans les données par lui-même.

- **Partitionnement (Clustering)**

- Détecter des groupes d'observations similaires.
- Ex : Segmenter les visiteurs d'un blog en groupes (visiteurs du soir, passionnés de SF, etc.).

- **Visualisation / Réduction de dimension**

- Représenter des données complexes de grande dimension en 2D ou 3D pour les humains.
- Simplifier les données sans perdre trop d'information (ex : agréger "âge" et "kilométrage" en "vétusté").

- **Détection d'anomalies (ou de nouveautés)**

- Apprendre à quoi ressemblent des données "normales" pour détecter ce qui est "inhabituel".
- Ex : Transactions de carte bancaire frauduleuses, défauts de fabrication.

Table des matières

- 1 Introduction au Machine Learning
- 2 Les Types d'Apprentissage
- 3 Classification**
- 4 Régression
- 5 Evaluer un modèle
- 6 Défis de l'apprentissage automatique
- 7 Conclusion

Définition Formelle

Soit un ensemble de données d'entraînement $\mathcal{D} = \{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$ où :

- $x^{(i)} \in \mathbb{R}^n$ est le vecteur de caractéristiques de la i -ème instance.
- $y^{(i)} \in \mathcal{Y}$ est l'étiquette de classe, où $\mathcal{Y}$ est un ensemble fini et discret de valeurs.

L'objectif est d'apprendre une fonction de prédiction $f : \mathbb{R}^n \rightarrow \mathcal{Y}$ telle que $f(x) \approx y$ pour les nouvelles données.

- **Essentiel** : Contrairement à la régression (où $\mathcal{Y} = \mathbb{R}$), ici la sortie est une **catégorie**.
- **Exemple** : x est un email, $\mathcal{Y} = \{\text{Spam}, \text{Non-Spam}\}$.

L'ensemble de données MNIST

- **Quoi** : 70 000 petites images de chiffres manuscrits.
- **Instances** : 70 000 images.
- **Caractéristiques (Features)** : Chaque image fait 28x28 pixels. Elle est "aplatie" en un vecteur de **784 caractéristiques** (une par pixel).
- **Valeurs** : Intensité du pixel (0 = blanc, 255 = noir).
- **Étiquettes (Classes)** : Le chiffre représenté (de "0" à "9").
- **Problème** : Classification multiclasse (10 classes).



- Cas particulier où l'ensemble des étiquettes ne contient que deux valeurs : $\mathcal{Y} = \{0, 1\}$ ou $\{-1, 1\}$.
- Souvent, on cherche à détecter la présence d'une classe spécifique (Classe Positive).

Exemple : Le "Déecteur de 5" (depuis MNIST)

- **Classe Positive** : "Est un 5"
- **Classe Négative** : "N'est pas un 5" (donc 0, 1, 2, 3, 4, 6, 7, 8, ou 9).

C'est la base de nombreux systèmes (Spam/Non-Spam, Malade/Sain, etc.).

Table des matières

- 1 Introduction au Machine Learning
- 2 Les Types d'Apprentissage
- 3 Classification
- 4 Régression**
- 5 Evaluer un modèle
- 6 Défis de l'apprentissage automatique
- 7 Conclusion

Définition Formelle

Soit un ensemble de données d'entraînement $\mathcal{D} = \{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$ où :

- $x^{(i)} \in \mathbb{R}^n$ est le vecteur de caractéristiques de la i -ème instance.
- $y^{(i)} \in \mathbb{R}$ est la valeur cible continue.

L'objectif est d'apprendre une fonction de prédiction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ telle que $f(x) \approx y$ pour les nouvelles données.

- Contrairement à la classification (où $\mathcal{Y}$ est discret), ici la sortie est une **valeur continue**.
- **Exemple** : x est la surface d'une maison, $y \in \mathbb{R}$ est son prix.

Le Jeu de Données California Housing

- **Contexte** : Données sur le logement en Californie (recensement de 1990).
- **Objectif (y)** : Prédire la valeur médiane des maisons dans un district (en centaines de milliers de \$).
- **Caractéristiques (x)** : 8 variables, dont :
 - MedInc : Revenu médian du district.
 - HouseAge : Âge médian des maisons.
 - AveRooms : Nombre moyen de pièces par logement.
 - Latitude/Longitude : Localisation géographique.

Table des matières

- 1 Introduction au Machine Learning
- 2 Les Types d'Apprentissage
- 3 Classification
- 4 Régression
- 5 Evaluer un modèle**
- 6 Défis de l'apprentissage automatique
- 7 Conclusion

- Entraîner un modèle, c'est bien.
- Savoir s'il est *bon*, c'est mieux.
- Comment évaluer un classifieur ou un régresseur ?
- Et surtout : **sur quelles données ?**

Tout pour l'entraînement : un score trompeur


vu pendant l'entraînement

Entraînement
100 %

aucune donnée mise de côté

- Un modèle qui **mémorise** son **jeu d'entraînement** y obtient un score parfait, et peut ne rien valoir sur de nouvelles données.
- L'**erreur d'entraînement** est donc un estimateur *optimiste* : elle mesure la mémorisation autant que l'apprentissage.

Réserver un jeu de test



- Ce qui compte, c'est l'**erreur de généralisation**, mesurée sur des **données jamais vues**.
- D'où la règle : on met le **jeu de test** de côté **avant** d'entraîner, et on ne le regarde qu'à la fin.
- **La limite** : il faut pourtant *choisir* (le modèle, ses réglages), et comparer ces choix demande des **données non vues**. Le seul bloc disponible est le test : on finit par y toucher, et le score qu'il donne redevient optimiste.

Entraînement, Validation, Test



- La **validation** sert à *choisir*; le **test**, uniquement à *estimer* — une seule fois, à la toute fin.

À retenir

Une métrique calculée sur le jeu d'entraînement ne dit rien de la généralisation : toutes celles qui suivent se mesurent sur des **données non vues**.

- Avant de définir des métriques, il faut un outil pour **compter les erreurs**.
- **Idée** : Compter le nombre de fois où la classe A est classée comme classe B.
- Pour un classifieur binaire (Positif / Négatif) :

	Prédit : Négatif	Prédit : Positif
Réel : Négatif	Vrais Négatifs (VN)	Faux Positifs (FP)
Réel : Positif	Faux Négatifs (FN)	Vrais Positifs (VP)

Comprendre la Matrice de Confusion

- **Vrais Positifs (VP)** : Un « 5 » (réel) qui a été prédit comme « 5 » (correct).
- **Vrais Négatifs (VN)** : Un « 3 » (réel) qui a été prédit comme « non-5 » (correct).
- **Faux Positifs (FP)** : Un « 3 » (réel) qui a été prédit comme « 5 » (incorrect).
 - *Erreur de Type I.*
- **Faux Négatifs (FN)** : Un « 5 » (réel) qui a été prédit comme « non-5 » (incorrect).
 - *Erreur de Type II.*

Note

Un classifieur parfait n'aurait que des VP et des VN. Les cases FP et FN seraient à zéro.

Métrique 1 : La Justesse (Accuracy)

- **Définition** : Ratio de prédictions correctes.
- **Formule** :

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN}$$

- **Intuition** : Si le modèle classe 95 images sur 100 correctement, sa justesse est de 95%.
- **Problème** : La justesse est une métrique trompeuse pour les **jeux de données déséquilibrés**.

Le Piège de la Justesse (Accuracy)

- **Jeu de données déséquilibré (Skewed dataset)** : Une classe est beaucoup plus fréquente que l'autre.
- **Exemple avec un détecteur de 5** : Dans MNIST, environ 10% des images sont des « 5 », et 90% sont des « non-5 ».
- **Expérience de pensée** : Créons un classifieur stupide, le « ClassifieurJamais5 », qui prédit **toujours** « non-5 ».
- **Performance** :
 - Il aura raison sur tous les « non-5 » (90% des données).
 - Il aura tort sur tous les « 5 » (10% des données).
 - **Sa justesse est de 90% !**
- **Conclusion** : Un score de justesse élevé peut être atteint par un modèle totalement inutile. **La justesse n'est pas une bonne métrique ici.**

Métrique 2 : La Précision (Precision)

La matrice de confusion nous donne deux métriques bien meilleures que la justesse. La première :

Précision

- **Question** : *Parmi toutes les fois où le modèle a dit « 5 », quel pourcentage de fois avait-il raison ?*
- Mesure la proportion de prédictions **positives** qui sont correctes.

$$\text{Précision} = \frac{VP}{VP + FP}$$

- **Lecture** : Colonne « Prédit : Positif » de la matrice.
- **Haute Précision** = Peu de Faux Positifs.

Métrie 3 : Le Rappel (Recall)

La seconde :

Rappel / Sensibilité

- **Question** : *Parmi tous les « 5 » qui existaient réellement, quel pourcentage le modèle a-t-il réussi à trouver ?*
- Mesure le taux de détection des instances **positives**.

$$\text{Rappel} = \frac{VP}{VP + FN}$$

- **Lecture** : Ligne « Réel : Positif » de la matrice.
- **Haut Rappel** = Peu de Faux Négatifs.

Précision vs. Rappel

Quelle métrique privilégier ? Tout dépend de **l'erreur qui coûte le plus cher**.

Privilégier la Précision quand un FP coûte cher


- *Exemple* : Filtre « sûr pour les enfants », avec **classe positive** = « **vidéo sûre** ». On préfère bloquer une vidéo sûre (FN) plutôt que de laisser passer une vidéo dangereuse (FP).

Privilégier le Rappel quand un FN coûte cher

- *Exemple* : Détection de voleurs. On préfère signaler un innocent (FP) plutôt que de manquer un vrai voleur (FN).

Le Seuil de Décision

- Un classifieur ne répond pas « oui / non » directement : il calcule d'abord un **score** de confiance (« à quel point cette image ressemble à un 5 »).
- La décision vient d'une comparaison : **score** $\geq$ **seuil** $\rightarrow$ **positif**, sinon négatif.
- Le seuil **ne s'apprend pas** avec le modèle : c'est un réglage, fixé après l'entraînement sur le jeu de **validation**.



Chaque point est une image : **disque plein** = un vrai « 5 », cercle gris = un « non-5 ». À ce seuil : 6 VP, 1 FP (le cercle à droite), 2 FN (les disques à gauche), 7 VN.


Compromis Précision/Rappel

- Précision **et** rappel à 100% : presque jamais.
- Le **seuil** ne supprime pas les erreurs, il les **transfère**.

Seuil	FN	FP	Rappel	Précision
↑ plus strict	+	−	↓	(↑)
↓ plus laxiste	−	+	↑	(↓)

() : vrai en général, pas garanti.

Le Compromis Précision/Rappel : illustration



Seul le **rappel** est monotone : il ne peut que baisser quand le seuil monte. La précision, elle, oscille — on retire à la fois des Vrais Positifs et des Faux Positifs, et rien ne garantit le sens de $VP/(VP + FP)$.

Métrique 4 : Le Score F1

- Quand aucune des deux erreurs ne prime clairement, il est pratique d'avoir une seule métrique qui combine Précision et Rappel.
- **Score F1** : La **moyenne harmonique** de la précision et du rappel.

$$F_1 = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

Pourquoi une moyenne harmonique ?


- Elle donne beaucoup plus de poids aux **faibles valeurs**.
- Un modèle n'aura un score F1 élevé que si la **précision ET le rappel sont élevés**.
- *Exemple* : Précision 90%, Rappel 10% → Moyenne simple = 50% (trompeur). Score F1 = 18% (reflète bien le mauvais rappel).

Courbe Précision-Rappel (PR)

- Pour choisir le meilleur seuil, on peut calculer la précision et le rappel pour *tous* les seuils possibles.
- On trace ensuite la **Précision en fonction du Rappel**.

Lire la Courbe Précision-Rappel

Courbe précision-rappel (AP = 0.90)



Comment la lire

- Chaque point = **un seuil**.
- On vise le **coin supérieur droit**.
- On choisit souvent le point « juste avant la chute » de la précision.

- Taux de Vrais Positifs (TVP) en fonction du Taux de Faux Positifs (TFP).


$$\text{Taux de Vrais Positifs : TVP} = \frac{VP}{VP + FN}$$

Autre nom du **Rappel** (ou Sensibilité).

$$\text{Taux de Faux Positifs : TFP} = \frac{FP}{FP + VN}$$

Part des instances *negatives* classées positives à tort.

Lire la Courbe ROC



Comment la lire

- Classifieur **aléatoire** : la diagonale.
- Classifieur **parfait** : coin supérieur gauche (TVP = 1, TFP = 0).
- **AUC** = aire sous la courbe : 1,0 = parfait, 0,5 = aléatoire.



Courbe PR vs. Courbe ROC

Tout se joue sur **un dénominateur**.

$$\text{ROC — axe X : TFP} = \frac{FP}{FP + VN}$$

Beaucoup de VN $\Rightarrow$ le TFP reste bas malgré les FP $\Rightarrow$ courbe **trop optimiste**.

$$\text{PR — axe Y : Précision} = \frac{VP}{VP + FP}$$

Pas de VN $\Rightarrow$ chaque FP fait **chuter** la courbe.

À retenir

Classe positive **rare** $\rightarrow$ **PR**. Classes équilibrées $\rightarrow$ ROC convient.

Mesurer la Performance (Régression)

- En classification, on comptait les succès/échecs (Justesse, Précision...).
- En régression, on doit quantifier la **magnitude de l'erreur**.
 - Une prédiction de 15 251 € n'est pas « 100% fausse » si la cible est 15 250 €. Elle est juste « proche ».
- **Objectif** : Mesurer à quel point, en moyenne, les prédictions ($\hat{y}$) sont éloignées des valeurs réelles (y).

Métriques principales :

- 1 RMSE (Root Mean Squared Error)
- 2 MAE (Mean Absolute Error)
- 3 R^2 (Coefficient de Détermination)

Métrique 1a : MSE (Erreur Quadratique Moyenne)

- Pour comprendre le RMSE, il faut d'abord comprendre le MSE.

MSE (Mean Squared Error) :

On calcule la moyenne des *carrés* des erreurs.

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2$$

- **Problème** : L'unité est au carré (ex : "euros carrés"). Difficile à interpréter.

Métrique 1b : RMSE (Root Mean Squared Error)

RMSE (Racine de l'EQM) :

On prend la racine carrée du MSE pour revenir aux unités d'origine.

$$\text{RMSE} = \sqrt{\text{MSE}}$$

- **Interprétation** : C'est l'erreur de prédiction "typique" du modèle (ex : "le modèle se trompe en moyenne de 8 500 €").
- **Caractéristique clé** : Très sensible aux **outliers** (valeurs aberrantes) car l'erreur est élevée au carré avant la moyenne. Une grosse erreur est lourdement pénalisée.

Métrique 2 : MAE (Mean Absolute Error)

- Une alternative robuste au RMSE.

MAE (Erreur Absolue Moyenne) :

C'est la moyenne des *valeurs absolues* des erreurs.

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |\hat{y}^{(i)} - y^{(i)}|$$

- **Interprétation** : Très directe (ex : "en moyenne, les prédictions s'écartent de 5 000 € de la réalité").
- **Caractéristique clé : Robuste aux outliers**. Les grosses erreurs contribuent de manière linéaire, pas quadratique.
- **Quand l'utiliser ?** Idéal si vos données contiennent beaucoup de bruit ou d'erreurs de saisie que vous ne voulez pas voir dominer la métrique.

Métrique 3 : Coefficient de Détermination (R^2)

- Métrique de **qualité d'ajustement** : on compare le modèle à celui qui prédirait toujours la moyenne $\bar{y}$.

$$R^2 = 1 - \frac{\sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2}{\sum_{i=1}^m (y^{(i)} - \bar{y})^2} = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

Interprétation :

- $R^2 = 1$: ajustement parfait ($SS_{\text{res}} = 0$).
- $R^2 = 0$: le modèle fait aussi bien que la moyenne.
- $R^2 < 0$: il fait *pire* que la moyenne.

Limitation : le R^2 dépend du jeu de données

Sur l'**entraînement**, il augmente toujours si l'on ajoute une caractéristique, même inutile. Sur le **test**, une caractéristique inutile le fait au contraire baisser.

Diagnostic : L'Analyse des Résidus

- Les métriques (RMSE, R^2) donnent un seul chiffre, mais ne disent pas *comment* le modèle se trompe.
- Un **résidu** est simplement l'erreur pour une seule instance : $e_i = y_{\text{réel}}^{(i)} - \hat{y}_{\text{prédit}}^{(i)}$.
- **Outil de diagnostic** : On trace les valeurs prédites ($\hat{y}$) sur l'axe X et les résidus (e) sur l'axe Y.

Interprétation :

- **Un bon modèle** : Le graphique doit être un nuage de points **aléatoire**, centré sur 0, sans structure. Les erreurs sont du "bruit".
- **Forme de cône** : Hétéroscédasticité (l'erreur augmente quand la prédiction augmente ; le modèle est moins fiable pour les grosses valeurs).
- **Forme de courbe (U)** : Le modèle linéaire manque une relation non-linéaire.

Table des matières

- 1 Introduction au Machine Learning
- 2 Les Types d'Apprentissage
- 3 Classification
- 4 Régression
- 5 Evaluer un modèle
- 6 Défis de l'apprentissage automatique**
- 7 Conclusion


- La tâche principale est de sélectionner un algorithme et de l'entraîner sur des données.
- Les deux principaux écueils sont donc :
 - ① De **mauvaises données**
 - ② Un **mauvais algorithme**
- Commençons par les défis liés aux données.

Défi Données 1 : Quantité Insuffisante

- **L'analogie humaine** : Un enfant apprend ce qu'est une "pomme" avec peu d'exemples.
- **La réalité du ML** : La plupart des algorithmes ont besoin de *beaucoup* de données pour fonctionner correctement.
 - **Problèmes simples** : Souvent des milliers d'exemples.
 - **Problèmes complexes** (reconnaissance d'image, parole) : Souvent des millions d'exemples (sauf si l'on réutilise un modèle existant).
- Un manque de données rend difficile la détection de motifs fiables.

- **Objectif** : Le modèle doit bien *généraliser* à de nouveaux cas inconnus.
- **Condition** : Pour cela, les données d'entraînement *doivent être représentatives* de ces nouveaux cas.
- **Bruit d'échantillonnage** : Si l'échantillon est trop petit, les données peuvent être non représentatives par pur hasard.
- **Biais d'échantillonnage** : Si la *méthode* de collecte est défectueuse, même un grand échantillon sera biaisé.

Exemple : Données Non Représentatives



Prédire la satisfaction de vie

- Le modèle entraîné sur un échantillon tronqué (ligne pointillée) diffère nettement de celui entraîné sur l'ensemble des pays (ligne pleine).
- Il manquait à l'échantillon les pays les **plus pauvres** et les **plus riches** (en rouge) : ce sont ces deux extrémités qui aplatissent la tendance.

Cas d'Étude : Biais d'Échantillonnage (1936)

The Literary Digest NEW YORK OCTOBER 31, 1936

Topics of the day

LONDON, 1,293,669; ROOSEVELT, 972,897

Final Returns in The Digest's Poll of Ten Million Voters

Well, the great battle of the ballots in the Poll of ten million voters, scattered throughout the forty-eight States of the Union, is now finished, and in the table below we record the figures received up to the hour of going to press.

These figures are exactly as received from more than one in every five voters polled in our country—they are neither weighted, adjusted nor interpreted.

Never before in an experience covering more than a quarter of a century in taking polls have we received so many different varieties of criticism—praise from many; condemnation from many others—and yet it has been just of the same type that has come to us every time a Poll has been taken in all these years.

A telegram from a newspaper in California asks: "Is it true that Mr. Hearst has purchased THE LITERARY DIGEST?" A telephone message only the day before these lines were written: "Has the Repub-

lican National Committee purchased THE LITERARY DIGEST?" And all types and varieties, including: "Have the Jews purchased THE LITERARY DIGEST?" "Is the Pope of Rome a stockholder of THE LITERARY DIGEST?" And so it goes—all equally absurd and amusing. We could add more to this list, and yet all of these questions in recent days are but repetitions of what we have been experiencing all down the years from the very first Poll.

Problem—Now, are the figures in this Poll correct? In answer to this question we will simply refer to a telegram we sent to a young man in Massachusetts the other day in answer to his challenge to us to wager \$100,000 on the accuracy of our Poll. We wired him as follows:

"For nearly a quarter century, we have been taking Polls of the voters in the forty-eight States, and especially in Presidential years, and we have always merely mailed the ballots, counted and recorded those

returned and let the people of the Nation draw their conclusions as to our accuracy. So far, we have been right in every Poll. Will we be right in the current Poll? That, as Mrs. Roosevelt said concerning the President's reelection, is in the 'lap of the gods.'

"We never make any claims before election but we respectfully refer you to the opinion of one of the most quoted citizens to-day, the Hon. James A. Farley, Chairman of the Democratic National Committee. This is what Mr. Farley said October 14, 1936:

"Any sane person can not escape the implication of such a gigantic sampling of popular opinion as is embraced in THE LITERARY DIGEST straw vote. I consider this conclusive evidence as to the desire of the people of this country for a change in the National Government. THE LITERARY DIGEST poll is an achievement of no little magnitude. It is a Poll fairly and correctly conducted."

In studying the table of the voters from

The statistics and the material in this article are the property of Funk & Wagnalls Company and have been copyrighted by it; neither the whole nor any part thereof may be reprinted or published without the special permission of the copyright owner.

Le sondage :

- Le *Literary Digest* envoie 10M de bulletins pour l'élection présidentielle US (Landon vs. Roosevelt).
- La réponse : 2,4M de réponses reçues.
- La prédiction : Victoire écrasante de Landon.
- Le résultat : Victoire écrasante de Roosevelt.

FIGURE 5. Returns in the *Literary Digest*'s mass mail-in poll of 1936 suggested Alf Landon was headed for an easy victory over President Franklin D. Roosevelt. The poll missed the outcome by almost twenty percentage points. (Credit: *Literary Digest*)

Cas d'Étude : Biais d'Échantillonnage (1936) - Pourquoi l'échec ?

The Literary Digest NEW YORK OCTOBER 31, 1936

Topics of the day

LONDON, 1,293,669; ROOSEVELT, 972,897

Final Returns in The Digest's Poll of Ten Million Voters

Well, the great battle of the ballots in the Poll of ten million voters, scattered throughout the forty-eight States of the Union, is now finished, and in the table below we record the figures received up to the hour of going to press.

These figures are exactly as received from more than one in every five voters polled in our country—they are neither weighted, adjusted nor interpreted.

Never before in an experience covering more than a quarter of a century in taking polls have we received so many different varieties of criticism—praise from many; condemnation from many others—and yet it has been just of the same type that has come to us every time a Poll has been taken in all these years.

A telegram from a newspaper in California asks: "Is it true that Mr. Hearst has purchased THE LITERARY DIGEST?" A telephone message only the day before these lines were written: "Has the Repub-

lican National Committee purchased THE LITERARY DIGEST?" And all types and varieties, including: "Have the Jews purchased THE LITERARY DIGEST?" "Is the Pope of Rome a stockholder of THE LITERARY DIGEST?" And so it goes—all equally absurd and amusing. We could add more to this list, and yet all of these questions in recent days are but repetitions of what we have been experiencing all down the years from the very first Poll.

Problem—Now, are the figures in this Poll correct? In answer to this question we will simply refer to a telegram we sent to a young man in Massachusetts the other day in answer to his challenge to us to wager \$100,000 on the accuracy of our Poll. We wired him as follows:

"For nearly a quarter century, we have been taking Polls of the voters in the forty-eight States, and especially in Presidential years, and we have always merely mailed the ballots, counted and recorded those

returned and let the people of the Nation draw their conclusions as to our accuracy. So far, we have been right in every Poll. Will we be right in the current Poll? That, as Mrs. Roosevelt said concerning the President's reelection, is in the 'lap of the gods.'

"We never make any claim before election but we respectfully refer you to the opinion of one of the most quoted citizens to-day, the Hon. James A. Farley, Chairman of the Democratic National Committee. This is what Mr. Farley said October 14, 1932:

"Any sane person can not escape the implication of such a gigantic sampling of popular opinion as is embraced in THE LITERARY DIGEST straw vote. I consider this conclusive evidence as to the desire of the people of this country for a change in the National Government. THE LITERARY DIGEST poll is an achievement of no little magnitude. It is a Poll fairly and correctly conducted."

In studying the table of the voters from

"The statistics and the material in this article are the property of Funk & Wagnalls Company and have been copyrighted by it; neither the whole nor any part thereof may be reprinted or published without the special permission of the copyright owner."

Pourquoi l'échec ? Le Biais d'échantillonnage

- ❶ **Biais de source** : Les adresses provenaient d'annuaires téléphoniques et de listes de membres de clubs. Ces listes favorisaient les personnes plus riches, plus susceptibles de voter Républicain (Landon).
- ❷ **Biais de non-réponse** : Moins de 25% ont répondu. Ceux qui ont répondu n'étaient pas représentatifs de l'ensemble des votants (ex : excluant les moins politisés).

FIGURE 5. Returns in the *Literary Digest's* mass mail-in poll of 1936 suggested Alf Landon was headed for an easy victory over President Franklin D. Roosevelt. The poll missed the outcome by almost twenty percentage points. (Credit: *Literary Digest*)

Défi Données 3 : Données de Mauvaise Qualité

- Votre système aura du mal à apprendre si les données sont pleines **d'erreurs, de valeurs aberrantes (outliers) et de bruit**.
- Le nettoyage des données ("data cleaning") est une étape cruciale et souvent longue du travail d'un data scientist.

Actions de nettoyage courantes :

- Si des instances sont des **valeurs aberrantes** claires : les supprimer ou les corriger manuellement.
- Si des instances ont des **caractéristiques manquantes** (ex : âge non renseigné) :
 - Ignorer l'instance.
 - Ignorer la caractéristique (si elle manque trop souvent).
 - Combler ("imputer") les valeurs (ex : par l'âge médian).
 - Entraîner des modèles avec et sans la caractéristique.

Défi Données 4 : Caractéristiques Non Pertinentes

- **Adage** : "Garbage In, Garbage Out" (À données médiocres, résultats médiocres).
- Le système ne peut apprendre que si les données contiennent suffisamment de caractéristiques **pertinentes** et pas trop **d'inutiles**.


L'Ingénierie des Fonctionnalités (Feature Engineering)

- **Sélection de caractéristiques** : Choisir les plus utiles parmi celles existantes.
- **Extraction de caractéristiques** : Combiner des caractéristiques pour en créer une plus utile (ex : "vétusté" = "âge" + "kilométrage").
- **Création de nouvelles caractéristiques** : Collecter de nouvelles données pour créer de nouvelles variables.

- Nous avons vu les problèmes de "mauvaises données".
- Voyons maintenant les problèmes de "mauvais algorithme".
- Les deux défis majeurs sont les extrêmes opposés :
 - ❶ **Le sous-apprentissage (Underfitting)**
 - ❷ **Le surapprentissage (Overfitting)**

Défi Algorithme 1 : Le Sous-apprentissage (Underfitting)


Sous-apprentissage (degré 1)



- **Définition** : Le modèle est **trop simple** pour apprendre la structure sous-jacente des données.
- **Exemple** : Tenter d'utiliser un modèle linéaire (une ligne droite) pour modéliser une relation non-linéaire (une courbe).
- **Symptôme** : Les prédictions sont mauvaises, **même sur les données d'entraînement**. Le modèle n'arrive tout simplement pas à "coller" aux données.

Défi Algorithme 1 : Le Sous-apprentissage (Underfitting) - Solutions

Sous-apprentissage (degré 1)




Solutions principales :

- 1 Sélectionner un modèle plus puissant (ex : passer d'un modèle linéaire à un modèle polynomial).
- 2 Fournir de meilleures caractéristiques au modèle (Feature Engineering).
- 3 Réduire les contraintes sur le modèle (ex : réduire la régularisation).

Défi Algorithme 2 : Le Surapprentissage (Overfitting)

Surapprentissage (degré 20)



- **Définition** : Le modèle fonctionne **très bien** sur les données d'entraînement, mais il **généralise mal** aux nouvelles données.
- **Analogie** : L'humain qui, arnaqué par un taxi, conclut que *tous* les taxis de ce pays sont des voleurs (surgénéralisation).
- **Cause** : Le modèle est **trop complexe** par rapport à la quantité ou au bruit des données.
 - Il n'apprend pas les vrais "signaux" des données, il **mémore le "bruit"**.
 - Ex : Il trouve un motif (par hasard) que "les pays avec un 'W' dans le nom ont une satisfaction de vie > 7 ".

- **Objectif** : Simplifier le modèle pour éviter qu'il n'apprenne le bruit.

Solutions principales :

① Simplifier le modèle :

- Choisir un modèle avec moins de paramètres (ex : linéaire au lieu de polynomial).
- Réduire le nombre de caractéristiques.
- Contraindre le modèle.

② Rassembler plus de données d'entraînement (pour que le "vrai" signal domine le "bruit").

③ Réduire le bruit dans les données (nettoyer les données).


Concept clé : La Régularisation

- C'est le processus de **contraindre un modèle** pour le rendre plus simple et réduire le risque de surapprentissage.
- L'objectif est de trouver le **juste équilibre** entre bien coller aux données d'entraînement et rester simple pour bien généraliser.

Comment ça marche ?

- La régularisation ajoute à la **fonction de coût** un terme qui pénalise les grands paramètres.
- Plus les paramètres sont grands, plus la pénalité est élevée.
- Cela force le modèle à utiliser des valeurs de paramètres plus petites, ce qui le rend plus simple et moins sujet au surapprentissage.

Le Compromis Biais-Variance



- **Biais** : l'erreur d'un modèle **trop simple**, qui se trompe toujours de la même façon → **sous-apprentissage** (erreur élevée en entraînement *et* en test).
- **Variance** : la sensibilité à l'échantillon **d'entraînement tiré**. Réentraîné sur d'autres données, le modèle serait très différent → **surapprentissage** (erreur faible en entraînement, élevée en test).

Le compromis

Plus de complexité → moins de biais, plus de variance. Le meilleur modèle est entre les deux.

Attention au mot « biais » : ici, une source d'erreur du modèle. Ce n'est ni le *biais d'échantillonnage* (vu plus haut), ni le paramètre θ_0 des modèles linéaires (module 2).

Table des matières

- 1 Introduction au Machine Learning
- 2 Les Types d'Apprentissage
- 3 Classification
- 4 Régression
- 5 Evaluer un modèle
- 6 Défis de l'apprentissage automatique
- 7 Conclusion**

Nous avons vu :

- ❶ Ce qu'est le ML (Tâche, Expérience, Performance).
- ❷ Les types majeurs (Supervisé vs. Non Supervisé).
- ❸ Focus sur la **Classification** (Binaire vs Multiclasse).
- ❹ Focus sur la **Régression** (Linéaire Simple vs Multiple).
- ❺ Le **protocole d'évaluation** (entraînement / validation / test) et les **métriques** de classification et de régression.
- ❻ Les **Défis Principaux** (Données, Algorithmes, compromis biais-variance).

Des questions ?